# DÉTECTION DES FAUX AVIS SUR LES PLATEFORMES EN LIGNE

A journey to Data Scientist 2

Members:

Rudresh Mishra Runlu Qu Jhonatan Torres Raymond Klutse



Date: Décembre 17, 2019

### SOMMAIRE

- 1. Contexte
- 2. Problématique
- 3. Comment résoudre le problème ?
- 4. Comment fonctionne-il?
- 5. Evaluation du fonctionnement
- 6. Notre recommandation



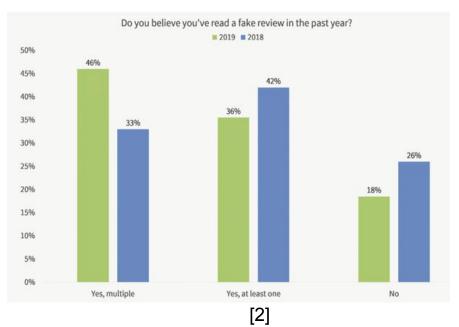


- L'authenticité des avis encourage la crédibilité des plateformes en ligne, ce qui attire beaucoup de gens.
- > 78 % des consommateurs font autant confiance aux avis en ligne qu'aux recommandations personnelles et 86 % des consommateurs lisent les avis en ligne avant de visiter une entreprise [1].
- D'après une étude par Harvard Business School, les notes plus élevé peuvent générer à peu près 9% de revenue pour les restaurants indépendant [1].









Cependant, l'apparition de faux avis commencé à détruire la crédibilité des plateformes et même les entreprises.

En 2019, 82 % des consommateurs ont lu un faux avis, contre 74 % l'an dernier [3].

68 % des consommateurs remettent en question l'authenticité des avis.

Seulement 9 % ont dit qu'ils ne remettent pas en question l'authenticité des avis, et 23 % ne sont pas certains [3].



Comme on peut le voir dans les actualités locales ou mondiales, l'enjeu de faux devient de plus en plus un grand problème.





[5]



## Qu'est-ce qu'un faux avis?

Un faux avis est celui qui trompe délibérément les lecteurs ou les systèmes d'exploration de l'opinion en donnant des avis positifs non méritées à certaines entreprises cibles afin de promouvoir ses entreprises et/ou en donnant des avis négatives injustes ou malveillantes à certaines entreprises afin de nuire à leur réputation [6].



# 2. PROBLÉMATIQUE



## 2. PROBLÉMATIQUE

Assurer l'authenticité des avis sur les plateformes en ligne de l'industrie hôtelière afin de garder leur crédibilité.







- > Nous proposons notre produit qui s'appelle LURJONRA.
- C'est un algorithme créé spécifiquement pour identifier les faux avis sur les plateformes en ligne basé sur le contenu d'avis et les comportements de utilisateurs et entreprises.
- En appliquant cet algorithme, la plateforme peut facilement détecter si un avis est vrai ou faux.



Notre produit vise à atteindre les jeunes plateformes d'avis en ligne pour l'industrie hôtelière qui se développent.







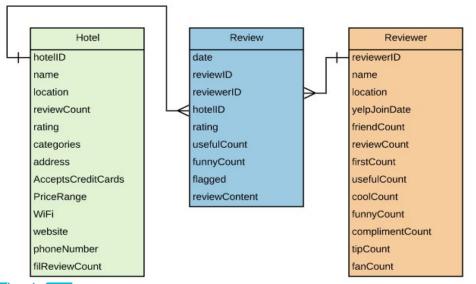
[10]

[9]

[8]



Pour créer un bon algorithme, nous avons exploré le jeu de données Yelp pour nous aider à trouver quelques caractéristiques que nous pouvons utiliser.

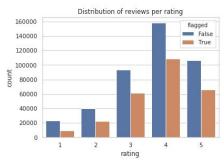


Hotel	283086 rows; 13 columns
Reviewer	5123 rows; 13 columns
Review	688329 rows; 9 columns

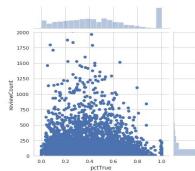


- La relation entre les vrais et les faux avis est plus forte dans les notes inférieures.
- Il y a une quantité croissante des avis et le nombre des faux avis augmente par rapport aux vrais avis au fil du temps.
- Il est possible d'extraire des variables qui décrivent le comportement des utilisateurs et des hôtels pour faciliter la classification des avis comme authentiques ou faux.

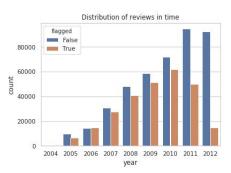




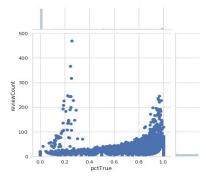
Répartition des avis par note



Scatterplot de le nombre d'avis par rapport au pourcentage d'avis réels par utilisateur



Répartition des avis dans le temps



Scatterplot de le nombre d'avis par rapport au pourcentage d'avis réels par hôtel

# Extraction de caractéristiques:

- > Sélection
- Nettoyage
- Création de nouvelles variables
- Intégration



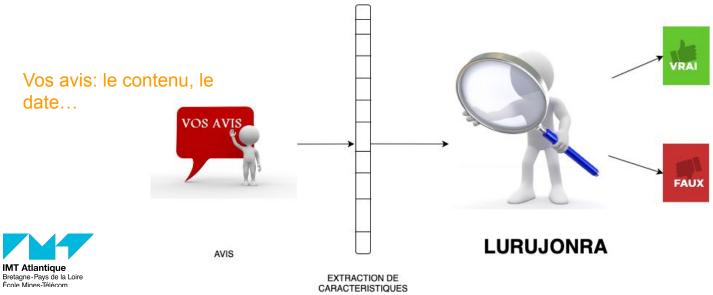
Nom	Signification	Example
reviewContent	Texte de l'avis	Let me begin by saying that there are two kind
rating_	Évaluation de l'avis	5
usefulCount	Nombre d'utilisateurs qui trouvent l'avis utile	18
flagged	Étiquette	False
weekDay	Jour de la semaine	Wednesday
wordsCount	Nombre de mots dans le texte	419
rating_r	Note moyenne de l'utilisateur	4.83333
reviewCount_r	Nombre d'avis effectués pour l'utilisateur	6
pctTrue_r	Pourcentage de vrais avis pour utilisateur	0
quantiles_r	Quantiles de la distribution des avis de l'utilisateur	[0.0, 0.0, 0.0, 0.0, 642.0]
meanTime_r	Moyenne de la distribution des avis de l'utilisateur	128.4
stdTime_r	Écart type de la distribution des avis de l'utilisateur	256.8
pct0_r	Pourcentage d'avis effectués le même jour	0.8
pctRatings_r	Pourcentage d'avis par note pour utilisateur	[0.0, 0.0, 0.0, 0.16, 0.83]
rating_h	Note moyenne de l'hôtel	3
reviewCount_h	Nombre d'avis effectués par l'hôtel	15
pctTrue_h	Pourcentage de vrais avis pour hôtel	0.33
quantiles_h	Quantiles de la distribution des avis de l'hôtel	[0.0, 1.5, 60.5, 176.25, 363.0]
meanTime_h	Moyenne de la distribution des avis de l'hôtel	105.786
stdTime_h	Écart type de la distribution des avis de l'hôtel	115.568
pct0_h	Pourcentage d'avis effectués le même jour	0.285714
pctRatings_h	Pourcentage d'avis par note pour hôtel	[0.4, 0.0, 0.13, 0.13]

# 4. COMMENT FONCTIONNE-IL?



#### 4. COMMENT FONCTIONNE-IL?

- Lorsque vous écrivez un commentaire, la base de données aura l'enregistrement de votre commentaire, comme la date, la durée du commentaire, votre comportement précédent, le contenu de votre commentaire.
- L'algorithme le traitera et donnera une note ('0' ou '1') où '0' est un faux commentaire et'1' est considéré comme un vrai commentaire.



#### 4. COMMENT FONCTIONNE-IL?

- Nous voulons rendre notre produit transparent afin de pouvoir justifier les résultats à l'entreprise (si demandé).
- Nous remarquons qu'il est important de savoir pourquoi l'algorithme a marqué un avis comme faux ou vrai en fonction des caractéristiques du comportement de l'utilisateur et l'hôtel.
- Ayant considéré cela, nous avons choisi d'utiliser la forêt aléatoire. Ils sont capables de travailler avec une quantité considérable de variables comme celle que nous avons dans ce problème et d'extraire un sens du résultat en identifiant les variables les plus importantes dans la prise de décision.



# 5. EVALUATION DU FONCTIONNEMENT



#### 5. EVALUATION DU FONCTIONNEMENT

- L'algorithme peut détecter 88 % des faux avis réelles à partir d'une plateforme en ligne. La plateforme peut garantir un niveau de qualité des avis.
- L'algorithme affecte seulement 5 % des vraies avis de la plateforme. Les utilisateurs et les hôtels qui ont les vrais avis ne seront pas très affectés.
- Globalement, le résultat montre que l'algorithme est capable de répondre avec succès aux besoins soulevés.



## 6. NOTRE RECOMMANDATION



L'algorithme permet d'identifier les vrais et faux avis. Avec ces informations, il est recommandé à l'entreprise de masquer ou de signaler les faux avis.

Étant donné que cela peut entraîner des plaintes de certains utilisateurs, il est également recommandé d'indiquer au moment de la création de l'utilisateur que le contenu suspect peut être traité selon les considérations de l'entreprise.



# QUESTIONS?



#### **REFERENCES**

[1] 2018 Online Review Statistics You Need to Know Available: <a href="https://boast.io/2018-online-review-statistics-you-need-to-know">https://boast.io/2018-online-review-statistics-you-need-to-know</a>,

Accessed on: 16 December, 2019

[2] Local Consumer Review Survey 2019, Available:

https://www.brightlocal.com/research/local-consumer-review-survey/#influence-of-reviews, Accessed on: 16 December, 2019

[3] https://www.brightlocal.com/learn/fake-reviews-are-a-real-problem-8-statistics-that-show-why/\_, Accessed on: 16 December , 2019

[4]https://www.bbc.com/news/uk-47952165, Accessed on: 16 December, 2019

[5] http://www.leparisien.fr/economie/faux-avis-sur-internet-la-repression-des-fraudes-part-en-chasse-14-04-2019-8053215.php

[6] https://www.cs.uic.edu/~liub/FBS/opinion-spam-WSDM-08.pdf ,Accessed on: 16 December, 2019

[7] http://www.opteam.fr/certifications-management-de-projet/se-preparer, Accessed on: 16 December, 2019

[8] https://lovelymobile.news/new-online-platform-recommends-travel-hotspots-curated-by-social-media-post/, Accessed on: 16

December, 2019

[9] <a href="https://www.peek.com/">https://www.peek.com/</a>, Accessed on: 16 December, 2019

[10] https://www.ticino.ch/ Accessed on: 16 December, 2019

